**Аналитика рекламных событий в ClickHouse**

Илья Партанский. Аналитические базы данных и хранилища

**Окружение и воспроизведение.** Проект проверен в учебном Docker-образе yandex/clickhouse-server:latest, фактическая версия 22.1.3.7. Внутри контейнера последовательно выполнить `clickhouse-client --multiquery` с вводом из sql/01_storage.sql, 02_kpi.sql, 03_reports.sql и 04_administration.sql. Первое развёртывание предполагает отсутствие таблиц проекта в базе ad_analytics. Для чистого повтора удалить только эту учебную базу, затем повторить все четыре файла. Повторное обновление KPI выполняется отдельно файлом 02_kpi.sql. Даты генерации отсчитываются от today() на сервере: 30 календарных дней, включая текущий.

**Модель хранения.** База использует Atomic. Справочники channels и campaigns, сырые raw_ads_events и итоговая campaign_kpi имеют движок MergeTree. Первые два справочника малы; ORDER BY соответствует их идентификатору. В событиях используются UUID, Date, Enum8 для типа события, Decimal для денег и LowCardinality(String) для устройства и страны. Decimal сохраняет точные суммы до копеек; отношения KPI хранятся в Nullable(Float64).

Сырые данные разбиты по toYYYYMM(event_date), упорядочены по (campaign_id, event_date, channel_id, event_type, event_id). Первые два поля соответствуют основному запросу "кампания за период"; последнее поле задаёт устойчивый порядок событий, но ORDER BY не является ограничением уникальности. KPI имеет гранулярность кампания/дата/канал и ORDER BY (campaign_id, event_date, channel_id). Месячные партиции ограничивают число частей и позволяют удалять историю целыми месяцами. Для небольшого учебного набора index_granularity=1024 делает отсечение по первичному индексу наблюдаемым; на большом потоке размер гранулы следует выбирать по измерениям объёма и нагрузки.

**Данные и ETL.** Созданы 4 канала, 7 кампаний и 12120 событий. 12000 основных событий содержат показы, клики и конверсии, разные расходы, доходы, три устройства и четыре страны. Ещё 120 событий формируют три бизнес-сценария: показы без расходов, клики без конверсий и органические конверсии без показов/кликов/расходов. Связь кампании с каналом и попадание событий в период кампании проверены. Целевые аудитории различаются.

ETL группирует события по трём полям ключа и использует countIf для типов, sum для cost и revenue. Витрина строится целиком во временной таблице campaign_kpi_build, затем EXCHANGE TABLES атомарно меняет имена. Старый снимок удаляется. Читатели видят завершённый снимок; повторный ETL не удваивает суммы. Одновременные запуски ETL запрещены организационно: один владелец обновления. Снимок отражает события, прочитанные запросом построения. Для учебного объёма эта схема проще инкрементальных агрегатных состояний и позволяет пересчитывать исправления. Materialized View не используется: оно не требуется для полного снимка и само по себе не устраняет повторную вставку исходного события.

**Метрики и отчёты.** CTR = clicks / impressions, CVR = conversions / clicks, CPA = spend / conversions, ROI = (revenue - spend) / spend. CTR, CVR и ROI записаны в долях, CPA - в денежных единицах. При нулевом знаменателе nullIf возвращает NULL: неопределённое отношение не превращается в нулевую стоимость или доходность. Каждый тип нулевого знаменателя присутствует в загруженных данных. Суммы денег считаются до перевода в Float64.

Пять отчётов используют KPI: топ-5 кампаний по ROI за последние семь календарных дней включая сегодня; каналы по CPA; кампании с CTR ниже 0.01; динамика расходов и доходов для campaign_id=1; фактический расход против дневного бюджета. Для сводных отношений сначала суммируются числители и знаменатели. Неопределённые ROI/CPA исключаются из рейтингов. CTR без показов не сравнивается с порогом. Бюджетный отчёт строит сетку активных дней кампаний и заполняет отсутствующие расходы нулём, поэтому дни без событий не исчезают. Нулевой бюджет даёт NULL в доле использования бюджета; абсолютное отклонение остаётся определённым.

**TTL и системные таблицы.** В raw_ads_events и campaign_kpi задано удаление через 365 дней от event_date. ETL исключает уже истёкшие даты, даже если фоновое TTL-слияние ещё не произошло. Один срок хранения для сырого и итогового слоёв согласован с полным пересчётом витрины. TTL применяется при слияниях, поэтому физическое удаление не обязано происходить точно в момент наступления срока. В отдельной временной таблице проверено удаление строки старше 365 дней после OPTIMIZE FINAL; таблица теста удалена и не входит в решение. Справочники малы и сохраняются для расшифровки оставшейся истории.

04_administration.sql обращается к system.parts, system.merges и system.query_log, показывает DDL и EXPLAIN indexes=1. В проверенном снимке сырые данные занимали две месячные партиции, три активные части и 252424 байта; KPI - две партиции, две части и 3179 байт. Это наблюдение, части и размеры меняются при фоновых слияниях. Активных merges в момент запроса не было, что допустимо после короткой загрузки.

Первичный индекс для кампании 1 за семь дней отсекает сырые гранулы с 13 до 2, части с 3 до 2. Период пересекает границу октября и ноября, поэтому обе месячные партиции нужны. По query_log одинаковая сумма расходов 90.72 и доходов 16288 получена чтением 2048 строк raw против 123 строк KPI; read_bytes 45056 против 2706. Время обоих запросов около 1 мс; на таком наборе оно не доказывает устойчивого ускорения. Основное подтверждение - меньшее чтение и проверенный план.

**Проверка результата.** Полный чистый запуск четырёх SQL-файлов, пять отчётов, системные запросы и повторное обновление KPI завершились успешно. Собственный автоматизированный тест на Python независимо пересчитал исходные события и сравнил каждую из 123 групп: счётчики, точные денежные суммы и четыре отношения с допуском для Float64. Проверены уникальность UUID и ключа KPI, типы событий, устройства, страны, связи и границы дат. Все четыре метрики проверены на нулевых знаменателях. Собственные проверки отделены от сдаваемых файлов.